

交流异步电机智能控制系统*

杨 川 王小椿

(西安交通大学精密工程研究所机械制造系统工程国家重点实验室 西安 710049)

摘要 首次提出并设计了针对交流异步伺服电机直接转矩控制系统的神经网络自适应电动机 u-n 模型。该模型易于实现、实时性较好、能够克服低速状态下定子电阻变化及系统参数变化的影响。仿真及实验表明所设计的系统具有良好的控制性能。

关键词 直接转矩控制 智能控制 u-n 模型

Intellectual Control System of the Induction Motor

Yang Chuan Wang Xiaochun

(State Key Lab for Manufacturing Systems Engineering Xi'an Jiaotong University, Institute of Precision Engineering, Xi'an 710049, China)

Abstract A neural network adaptive motor u-n model for direct self-control system of the induction motor was firstly suggested and designed. This model is carried out easily to avoid the harmful influence of the change of stator resistance and system parameters under low speed situation. It is shown from both simulation and experiment results that the adoption of this model can get a good control performance.

Key words Direct torque control Intellectual control u-n Model

1 引 言

交流异步电机有三种磁链(电机)模型, u-i 模型、i-n 模型、u-n 模型。采用直接转矩控制时, 可以采用三种方法获得定子磁链: (1) 采用滑模变结构控制, 高速区采用 u-i 模型、低速区切换到 i-n 模型, 缺点是快速平滑切换很困难, 切换点难以确定; (2) 采用简单的 u-i 模型, 在低速区对定子电阻进行辨识或补偿。这种方法仅仅考虑定子电阻变化对控制性能的影响, 而不能顾及交流异步电动机其它参数变化带来的影响。另外, 辨识与模型的计算需要分别进行; (3) 采用综合了 u-i 和 i-n 模型的优点, 适合于整个速度范围的 u-n 模型。u-n 模型的控制性能远高于前两种方法, 但要求解多个非线性微分方程, 运算量很大, 实现比较复杂, 因此难以实际应用。

2 交流异步电机神经网络自适应 u-n 模型

对于感应式交流异步电机, 由电机数学模型中的

电压、电流、转子角速度和电磁转矩与定子磁链和转子磁链之间关系, 可推导出 α - β 坐标系下 u-n 模型方程: $p\Psi_a = u_a - R_s i_a$; $p\Psi_\beta = u_\beta - R_s i_\beta$; $p\Psi_a' = -R_r i_a' - \omega \Psi_\beta'$; $p\Psi_\beta' = -R_r i_\beta' - \omega \Psi_a'$ 。其工作原理是: 将实际测得的转子角速度与 α - β 坐标系下的两相定子电压和电流, 共同作为 u-n 模型的输入, 求解这些非线性微分方程便可得到 α - β 坐标系下的定子磁链。由公式 $T_e = P_m (i_a' \Psi_\beta' - i_\beta' \Psi_a')$ 还可得到电磁转矩。但是, 这种求解过程非常复杂, 难以在实际中实现。

已有研究表明, 在很宽的条件下, 三层前向神经网络能以任意的精度逼近任意连续函数及其各阶导数。其中, BP 神经网络是一种多层前向神经网络, 其神经元变换函数是 Sigmoid 函数, 它可以实现从输入到输出的任意非线性映射。而 BP 学习算法对神经网络权值的调整具有较强的容错性及自学习能力, 由此构成的 BP 神经网络不仅具有逼近任意非线性函数的能力, 而且结构和学习算法简单明了。另外, 经过训练的 BP 神经网络, 对于不是样本集中的输入也能给出合适的输出。因此, 可以考虑将其与 u-n 模型结合, 发挥二者的优点。

2.1 神经网络自适应 u-n 模型设计

交流异步电机 u-n 模型描述的是电机定子磁链与

* 本文于 2002 年 8 月收到。

定子电流、定子电压和电机转速之间的一种非线性映射关系。由于这种关系在实际计算过程中相当复杂,需要花费大量的运算时间。作者从BP神经网络具有逼近任意非线性函数的能力和具有较强的容错性及自学习能力的角度出发,首次提出并设计了基于BP学习算法的三层并行自适应神经网络,用于构成交流异步电机的神经网络自适应u-n模型。其特点是结构简单,易于在线进行自适应学习。当采样数据足以描述交流异步电机运行状态信息时,基于BP学习算法的三层并行神经网络是能够映射真实的交流异步电机模型的。在实际运行过程中,随着神经网络自学习的进行,神经网络自适应u-n模型能够自动适应电机参数和环境的变化,提高系统的控制性能。而且,对电机参数变化的自适应学习与u-n模型的计算同时进行,无需额外的实时计算时间,可满足电机实时控制的要求,神经网络模型如图1所示。图中每一个神经元都用标准化的神经元来表示,其结构如图2所示。




图1 神经网络 u-n 模型




图2 标准化神经元

图2中, $x_i^{(r)}(k)$ ——表示第 r 层神经元的输入 ($r=I$ (输入层)、 H (隐层)、 O (输出层)), 而且是该层第 i 个神经元的第 k 组样本、第 j 个输入 ($j=1, \dots, n$; n 表示该神经元有 n 个输入变量; 输入层 $n=1$ 、隐层 $n=3$ 、输出层 $n=6$); $w_{ji}^{(r)}(k)$ ——相应于 $x_i^{(r)}(k)$ 的加权系数; $y_i^{(r)}(k)$ ——表示第 r 层、第 i 个神经元的输出, ($i=1, \dots, m$; m 表示第 r 层有 m 个神经元; 输入层 $m=5$ 、隐层 $m=6+6$ 、输出层 $m=2$)。 $f(\cdot)$ ——神经元的活化函数; $f(u_i^{(r)}(k)) = 1/[1 + \exp(-u_i^{(r)}(k))]$; $u_i^{(r)}(k) = \sum_j x_{ji}^{(r)}(k) * w_{ji}^{(r)}(k)$; $y_i^{(r)}(k) = f(u_i^{(r)}(k))$ 。

2.2 神经网络自适应 u-n 模型学习

BP神经网络的学习过程,由前向传播和反向传播组成,在前向传播过程中,输入信息从输入层神经元经过隐层神经元逐层处理,并传向输出层,每一层神经元

的状态只影响下一层神经元的状态。如果在输出层不能得到期望的输出,则转入反向传播,将误差信号沿原来的连接通路返回,通过BP算法来修改各层神经元的权值,使得误差信号达到最小。

BP算法计算步骤为:

(1)选择输入变量的加权系数初值 $w_{ji}^{(r)}(0)$, $w_{ji}^{(r)}$ (0)中的元素为 $[-1, 1]$ 中的随机数。

(2)输入一个样本 $i(k)$ 、 $u(k)$ 、 $n(k)$ 、 $i(k-1)$ 、 $u(k-1)$ 、 $n(k-1)$ 。这里 k 表示当前的样本(或第 k 次采样数据),即第 k 个样本, $k-1$ 表示前一个样本,即第 $k-1$ 个样本。

(3)BP神经网络的前向计算:即在网络各神经元的活化函数及连接强度都确定的情况下,对于一个输入样本,先前向传播到隐层神经元,经过活化函数后,再将隐层神经元的输出信息前向传播到输出层神经元,最后得出输出结果。

对隐层: $y_i^{(H)}(k) = f(u_i^{(H)}(k))$

$$u_i^{(H)}(k) = \sum_j x_{ji}^{(H)}(k) * w_{ji}^{(H)}(k)$$

对输出层: $y_i^{(O)}(k) = f(u_i^{(O)}(k))$

$$u_i^{(O)}(k) = \sum_j x_{ji}^{(O)}(k) * w_{ji}^{(O)}(k)$$

对输入层: $y_i^{(I)}(k) = x_i^{(I)}(k)$

(4)BP神经网络的误差反向传播和加权系数的调整:如果在神经网络前向计算中得到的输出与样本的输出不一致,就需要将其误差信号从输出端反向传播回来,并在传播过程中对加权系数不断修正,使输出层神经元上得到所需要的期望输出为止。加权系数的调整采用 δ 学习规则,这是一种有教师示教按误差修正神经网络连接权的一种学习规则。为了加快收敛速度,在实际应用中采用自适应调整学习速率^[76]的改进 δ 规则学习算法。该学习算法是用梯度法极小化如下目标函数: $E_i(k) = \Delta^2/2$ 。

样本学习: $\Delta = y_{di}(k) - y_i^{(O)}(k)$, $i = \Psi_{\alpha}^s, \Psi_{\beta}^s$

实际运行: $\Delta = \Psi_{\alpha}^s - [(\Psi_{\alpha}^s)^2 + (\Psi_{\beta}^s)^2]^{1/2}$

式中: $y_{di}(k)$ ——第 k 个样本的输出; $E_i(k)$ ——对每一个样本 k ,所引入的二次型误差函数。

输出层加权系数调整公式:

$$w_{ji}^{(O)}(k+1) = w_{ji}^{(O)}(k) - \eta(k) (\partial E_i(k) / \partial w_{ji}^{(O)}(k)) + \lambda [w_{ji}^{(O)}(k) - w_{ji}^{(O)}(k-1)] \quad (1)$$

$$\partial E_i(k) / \partial w_{ji}^{(O)}(k) = [\partial E_i(k) / \partial y_i^{(O)}(k)] \cdot$$

$$[\partial^{(O)} y_i(k) / \partial^{(O)} w_{ji}(k)]$$

其中: $\partial E_i(k) / \partial^{(O)} y_i(k) = -(y_{di}(k) - y_i^{(O)}(k))$

$$\partial^{(O)} y_i(k) / \partial^{(O)} w_{ji}(k) = \partial f(u_i^{(O)}(k)) / \partial^{(O)} w_{ji}(k)$$

$$= [\partial u_i^{(O)}(k) / \partial w_{ji}^{(O)}(k)] [pf(u_i^{(O)}(k))]$$

$$= [\partial(\sum_j x_{ij}^{(0)}(k) * w_{ij}^{(0)}(k)) / \partial w_{ij}^{(0)}(k)] [pf(u_i^{(0)}(k))]$$

$$= x_i^{(0)}(k) [pf(u_i^{(0)}(k))] = y_i^{(H)}(k) [pf(u_i^{(0)}(k))]$$

当神经元的活化函数 $f(\cdot)$ 为 Sigmoid 函数时,有:

$$pf(u_i^{(0)}(k)) = f(u_i^{(0)}(k)) [1 - f(u_i^{(0)}(k))]$$

$$= y_i^{(0)}(k) [1 - y_i^{(0)}(k)]$$

$$\text{则: } \partial y_i^{(0)}(k) / \partial w_{ij}^{(0)}(k) = y_i^{(H)}(k) y_i^{(0)}(k) [1 - y_i^{(0)}(k)]$$

为避免混淆,将隐层的下标改成 t ,则有:

$$\partial y_i^{(0)}(k) / \partial w_{ij}^{(0)}(k) = y_i^{(H)}(k) y_i^{(0)}(k) [1 - y_i^{(0)}(k)]$$

$$\text{所以: } \partial E_i(k) / \partial w_{ij}^{(0)}(k) =$$

$$-(y_d(k) - y_i^{(0)}(k)) \{ y_i^{(H)}(k) y_i^{(0)}(k) [1 - y_i^{(0)}(k)] \}$$

$$\text{定义: } \delta_i^{(0)}(k) = y_i^{(0)}(k) (1 - y_i^{(0)}(k)) (y_d(k) - y_i^{(0)}(k))$$

因此输出层加权系数调整公式为:

$$w_{ij}^{(0)}(k+1) = w_{ij}^{(0)}(k) + \eta(k) \delta_i^{(0)}(k) y_i^{(H)}(k) +$$

$$\lambda [w_{ij}^{(0)}(k) - w_{ij}^{(0)}(k-1)]$$

同理可以推导出隐层加权系数调整公式:

$$w_{ij}^{(H)}(k+1) = w_{ij}^{(H)}(k) - \eta(k) (\partial E_i(k) / \partial w_{ij}^{(H)}(k)) +$$

$$\lambda [w_{ij}^{(H)}(k) - w_{ij}^{(H)}(k-1)] \quad (2)$$

$$= w_{ij}^{(H)}(k) + \eta(k) \delta_i^{(H)}(k) y_i^{(H)}(k) +$$

$$\lambda [w_{ij}^{(H)}(k) - w_{ij}^{(H)}(k-1)]$$

$$\delta_i^{(H)}(k) = y_i^{(H)}(k) (1 - y_i^{(H)}(k)) [\sum_j \delta_j^{(0)}(k) w_{ij}^{(0)}(k)]$$

式中: $\eta(k)$ ——加权系数的自适应调整学习速率, $0 \leq \eta \leq 1$; $\eta(k) = 2^{-k} \eta(0)$;

$$\tau = \text{sign} \{ [\partial E_i(k) / \partial w_{ij}^{(0)}(k)] \times [\partial E_i(k-1) / \partial w_{ij}^{(0)}(k-1)] \}$$

$$(k-1)] \}$$

$$(k-1)] \}$$

λ ——加权系数的惯性系数, $0 < \lambda < 1$;

下标 i ——表示上层节点号;下标 j ——表示下层节点号。

(5) 当进行完上述步骤后,输入下一个样本, $k=k+1$,返回到(3)。直到 $E(k)$ 收敛。

由于学习速率 η 值对学习过程的影响很大,学习速率 η 值小时,学习过程将很慢;其次,学习速率 η 值选择过大时,虽然可以提高学习速度,但又可能导致学习过程的振荡,从而收敛不到期望解;再其次,学习过程可能收敛于局部极小点或在误差函数的平稳段停止不前。为了提高收敛速度和改善动态性能,在连接权的调整公式中加入惯性项,以平滑权的变化。即当加入惯性项后,如果前一步权的变化较大,那么将这个量的一部分加到现行权的调整上必然会加速收敛过程。此外,当学习过程在目标函数曲面的平稳区域进行时,每一步的梯度 $(\partial E(k) / \partial w_{ij}(k))$ 将几乎不变,这时公式(1)、(2)可以近似写成:

$$w_{ij}^{(0)}(k+1) = w_{ij}^{(0)}(k) - \eta(\partial E_i(k) / \partial w_{ij}^{(0)}(k)) +$$

$$\lambda [w_{ij}^{(0)}(k) - w_{ij}^{(0)}(k-1)]$$

$$\approx w_{ij}^{(0)}(k) + [\eta / (1 - \lambda)] (\partial E_i(k) / \partial w_{ij}^{(0)}(k))$$

$$w_{ij}^{(H)}(k+1) = w_{ij}^{(H)}(k) - \eta(\partial E_i(k) / \partial w_{ij}^{(H)}(k)) +$$

$$\lambda [w_{ij}^{(H)}(k) - w_{ij}^{(H)}(k-1)]$$

$$\approx w_{ij}^{(H)}(k) + [\eta / (1 - \lambda)] (\partial E_i(k) / \partial w_{ij}^{(H)}(k))$$

即当有效学习速率增加到 $\eta / (1 - \lambda)$ 时,仍不会导致学习过程中的振荡。

3 仿真及实验

实验用交流异步电机参数: $U_e = 380V$; $I_e = 45.5A$; $f_e = 50Hz$; $T_e = 102.3N \cdot m$; $n_e = 1400r/min$; $R_s = 0.081\Omega$; $R_r = 0.055\Omega$; $L_s = 0.0203H$; $L_m = 0.0189H$; $L_r = 0.0197H$; $P_m = 2$; $J = 0.01kg \cdot m^2$ 。

3.1 仿真结果

用于交流异步电动机神经网络电动机模型学习过程是将 MATLAB 软件下设计的交流异步电动机直接转矩控制仿真系统运行过程中得到的数据作为样本,对神经网络 $u-n$ 模型进行学习,并将学习结果与仿真系统的输出数据进行比较,结果作为修改神经网络电动机模型权值的依据及停止学习的判据。

仿真工作状态:

0.5 倍额定转速及额定转矩下稳态运行,并加有 5% 的噪声。

由仿真系统输出的样本数据,按前述 BP 学习算法对神经网络电动机模型的权值进行自学习,初始学习速率选择为 $\eta(0) = 0.5$ 、惯性系数

$\lambda = 0.8$,学习 436 次




图3 神经网络 $u-n$ 模型学习误差

后,二者输出的误差都降低到 0.002 以下,神经网络学习误差的变化情况如图 3 所示。可见,神经网络电动机模型输出的 $\alpha-\beta$ 轴磁链分量 Ψ_s^* 、 Ψ_β^* 与仿真系统输出的磁链分量之间的误差,是能够较快地收敛于零。

学习结束后神经网络电动机 $u-n$ 模型的输出结果如图 4 所示。神经网络电动机模型经过学习后,达到设计要求,输出数据与样本数据基本相同。

3.2 实验结果(图中数据经过标么化)

实验条件:电动机带负载($T_L = 0.6T_e$),其神经网络电动机 $u-n$ 模型采用仿真时通过学习得到的模型。

图 5 是交流异步电动机带负载起动时,电流(A 相




图4 神经网络电动机模型输出

电流)、转矩、转速响应曲线。




图5 带载启动时电流、转矩、转速响应

图6是电机运行20min后,转速从-0.5至0.5(标么化值)反转时转矩、转速响应曲线。




图6 带负载反转时转矩、转速响应

由实验结果可见,采用神经网络电动机u-n模型后,转速响应的动态、静态特性都比较好,达到设计要求。

4 结 论

提出并设计了针对交流异步电动机直接转矩控制系统的神经网络自适应电动机u-n模型,该模型易于实现,实时性较好。同时,还能够克服低速状态下定子电阻变化带来的影响及其它系统参数变化的影响,实验结果说明达到了设计目标。

参考文献

- 1 Francesco B, et al.. An innovative direct self-control scheme for induction motors drives. IEEE Trans. On Power Electronics, 1997, (5):800~806.
- 2 Luis A, et al.. Learning techniques to train neural networks as a state selector for inverter-fed induction machines using direct torque control. IEEE Trans. On Power Electronics, 1997, (5):788~799.
- 3 李凤. 异步电动机直接转矩控制. 北京:机械工业出版社, 1998.
- 4 王耀南. 智能控制系统——模糊逻辑、专家系统、神经网络控制. 湖南:湖南大学出版社, 1996.
- 5 焦李成. 神经网络系统理论. 西安:西安电子科技大学出版社, 1995.
- 6 杨行峻, 郑君里. 人工神经网络. 北京:高等教育出版社, 1992.
- 7 王永骥, 涂建. 神经网络控制. 北京:机械工业出版社, 1998.

(上接第301页)

- day. IEEE Communications Magazine, 2002, 40(3):75~79.
- 3 胡强, 程耀东, 齐津. 主动控制的高精度隔振平台的仿真. 浙江大学学报, 1999, 33(2):209~213.
- 4 T. Fujita, Y. Tagawa, K. kajiwara, H. Yoshioka, A. Takeshita, M. yasuda. Active 6-DOF microvibration control system using piezoelectric actuator. Proceedings of the Third Conference on Adaptive Structures, San Diego, California, November 1992:514~528.
- 5 Y. Nakamura, M. Nakayama, K. Masuda, K. Tanka, M. Yasuda, T. Fujita. Development of active 6-DOF microvibration control system using giant magnetostrictive actuator. Proceedings of the SPIE Conference on Smart

Systems for Bridges, Structures and Highways, Newport Beach, California, March 1999:229~240.

- 6 杜耀武, 史习智. 结构振动的 H_2/H_∞ 混合最优控制. 振动工程学报, 1999, 12(3):103~108.
- 7 王德进. H_2 和 H_∞ 优化控制理论. 哈尔滨:哈尔滨工业大学出版社, 2001. 214~228.
- 8 庄表中, 李小平. 仿生学与振动. 振动与冲击, 1997, 16(1):84~85.
- 9 盖玉先, 董申, 李旦, 张明明. 超精密机床的振动混合控制. 中国机械工程, 2000, 11(3):289~291.
- 10 沙成满, 王恩德, 杨冬梅, 唐春安. 建筑结构振动主动控制的 H_2/H_∞ 混合凸优化方案. 东北大学学报(自然科学版), 2002, 23(12):1189~1192.